

Podstawy programowania R

Łukasz Wawrowski

Contents

Wprowadzenie	5
1 Wprowadzenie do R	7
1.1 Wprowadzenie	7
1.2 R	8
1.3 RStudio	9
1.4 Ważne informacje	9
1.5 Pakiety	11
1.6 R jako kalkulator	11
2 Struktury danych	13
2.1 Obiekty	13
2.2 Wektor	13
2.3 Macierz	23
2.4 Czynniki	28
2.5 Lista	29
2.6 Ramka danych	30
3 Przetwarzanie danych	35
3.1 Wprowadzenie - pakiet tidyverse	35
3.2 Import danych	36
3.3 Filtrowanie	38
3.4 Wybieranie kolumn	39
3.5 Tworzenie nowych zmiennych	39
3.6 Zmiana nazwy zmiennej	40
3.7 Podsumowanie danych	40
3.8 Grupowanie	41
3.9 Sortowanie	43
3.10 Łączenie zbiorów	43
3.11 Szeroka i wąska reprezentacja danych	45
3.12 Eksport danych	46
3.13 Zadania	46
3.14 Case study	47

4	Wizualizacja danych	49
4.1	Wprowadzenie	49
4.2	Wykres punktowy	50
4.3	Histogram	60
4.4	Wykres pudełkowy	64
4.5	Wykres słupkowy	68
4.6	Wykres kafelkowy	74
4.7	Uwzględnienie czasu	77
4.8	Facets	79
4.9	Wykres interaktywny	82
5	Programowanie w R	85
5.1	Instrukcje warunkowe	85
5.2	Funkcje	85
5.3	Pętle	86

Wprowadzenie

Polecana literatura:

- Garret Grolmund, Hadley Wickham - *R for Data Science* (polska wersja)
- Marek Gągolewski - *Programowanie w języku R. Analiza danych, obliczenia, symulacje.*

Skrypty z zajęć

Chapter 1


Wprowadzenie do R

Prezentacja

1.1 Wprowadzenie

GNU R to interpretowany język programowania oraz środowisko do obliczeń statystycznych i wizualizacji wyników [Wikipedia 2017].

Robert A. Muenchen - The Popularity of Data Science Software

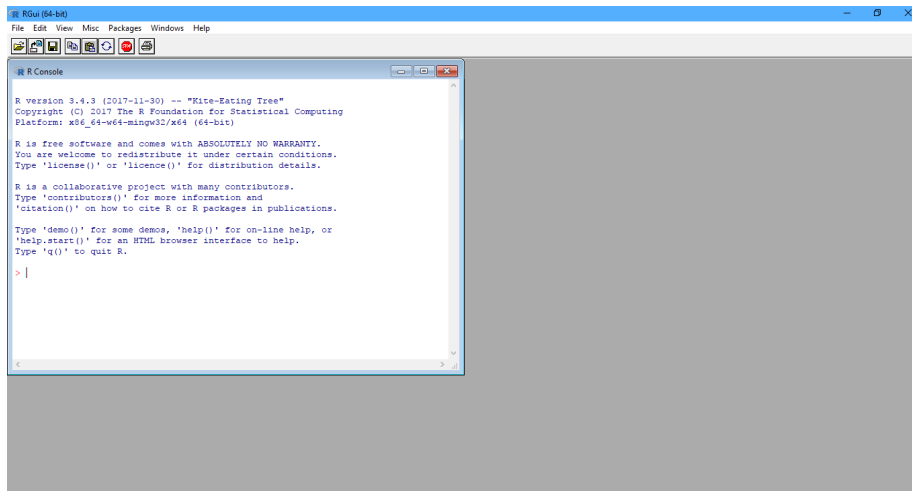


1.2 R

Bazowa wersja R jest do pobrania ze strony r-project.org.

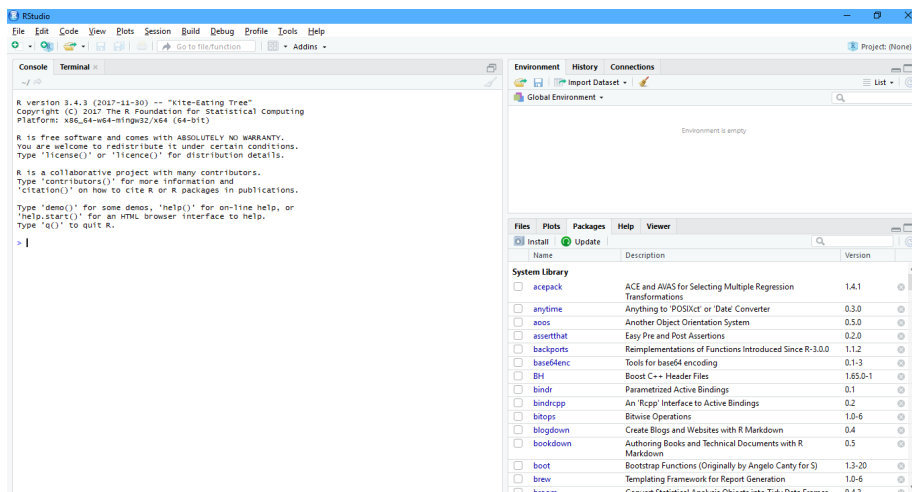
1.3. RSTUDIO

9



1.3 RStudio

RStudio to zintegrowane środowisko programistyczne (IDE) dla języka R dostępne za darmo na stronie RStudio.



Z R można także korzystać w Microsoft Visual Studio.

1.4 Ważne informacje

R jest wrażliwy na wielkość liter.

Separatorem części dziesiętnej liczby jest kropka.

W codziennej pracy RStudio jest wygodniejsze, jednak długotrwałe obliczenia lepiej uruchamiać w trybie wsadowym w zwykłym R.

- **Katalog roboczy**

Ważnym pojęciem w R jest katalog roboczy (ang. working directory), który określa gdzie zostaną zapisane pliki, wykresy, zbiory, itp. jeśli nie podamy dokładnej ścieżki do pliku. Katalog roboczy przypisuje się z wykorzystaniem funkcji `setwd("ścieżka do katalogu")`, a jego wartość można sprawdzić funkcją `getwd()`. W RStudio przypisanie katalogu roboczego odbywa się w momencie utworzenia projektu.

- **Projekt**

Katalog na dysku, w którym znajdują się wszystkie pliki projektu wraz z plikiem o rozszerzeniu `.Rproj` skojarzonym z RStudio.

- **Korzystanie z pomocy**

Dostęp do pomocy odnośnie wybranej funkcji można uzyskać na dwa sposoby. Pierwszym z nich jest poprzedzenie nazwy funkcji w konsoli znakiem zapytania np. `?getwd` lub wywołanie funkcji `help` na nazwie funkcji `help("getwd")`. Drugim sposobem jest umieszczenie kursora w dowolnym miejscu nazwy funkcji i wciśnięcie klawisza F1.

Internet - przede wszystkim stackoverflow.

- **Komentarze**

Real programmers don't comment their code. If it was hard to write it should be hard to understand.

Dobrze napisany kod jest czytelny bez komentarzy. W R komentarze rozpoczynają się od symbolu `#`. Skrót klawiaturowy w RStudio to CTRL + SHIFT + C (do wstawiania i usuwania komentarzy).

- **Podpowiadanie składni**

RStudio ma zaimplementowaną funkcję podpowiadania składni. Listę możliwych funkcji i obiektów wywołuję się klawiszem TAB lub CTRL + SPACJA po wpisaniu co najmniej jednej litery. Kolejne naciśnięcie TAB lub ENTER powoduje uzupełnienie kodu o wybraną funkcję lub obiekt.

- **Wykonywanie programów**

Programy w R możemy tworzyć jako skrypty w pliku tekstowym o rozszerzeniu `.R` lub wywoływać polecenia bezpośrednio w konsoli. Kod programu napisanego w skrypcie przekazywany jest do konsoli. Gotowość do pracy R sygnalizuje w konsoli znakiem zachęty `>`. Jeśli podczas wykonywania programu w konsoli pojawi się znak `+` to oznacza oczekiwanie na kompletny kod - brak domkniętego nawiasu, cudzysłowia, itp.:

```
> getwd(
```

+

W powyższym przykładzie brakuje prawego nawiasu. Dodanie brakującego kodu spowoduje wykonanie przekazanego polecenia. Z kolei wciśnięcie klawisza ESC spowoduje przerwanie wykonywania programu i powrót do znaku zachęty. Zawartość konsoli można wyczyścić stosując kombinację klawiszy CTRL + L.

- **Pliki**

Jeśli w pamięci znajdują się jakieś obiekty (zakładka Environment) to RStudio przy zamykaniu programu zapyta o zapisanie tych obiektów do pliku .RData. Jeżeli zdecydujemy się na tą propozycję to po ponownym uruchomieniu projektu obiekty znajdujące się w pliku .RData zostaną automatycznie wczytane do pamięci.

Można także samodzielnie tworzyć pliki o rozszerzeniu .RData z wykorzystaniem funkcji `save()`:

```
save(obiekt1, obiekt2, obiekt3, file = "nazwa_pliku.RData")
```

Wczytanie obiektów z takiego pliku do pamięci odbywa się z zastosowaniem funkcji `load()`:

```
load("nazwa_pliku.RData")
```

1.5 Pakiety

Podstawowe możliwości R są dosyć ograniczone. Rozszerzają je pakiety, których obecnie jest ponad 12 tysięcy. Można je przeglądać według kategorii w CRAN Task Views lub w wygodnej wyszukiwarce METACRAN i rdr.io.

1.6 R jako kalkulator

Działania matematycznie w R:

Operator	Operacja
+	dodawanie
-	odejmowanie
*	mnożenie
/	dzielenie
^ lub **	potęgowanie
sqrt()	pierwiastkowanie

W R istnieje także stała wbudowana `pi` przechowująca wartość liczby pi.

Funkcja `factorial(x)` zwraca silnię (znak wykrzyknika !) z podanej wartości `x`, a `sign(x)` sprawdza znak wyrażenia i zwraca odpowiednio wartość -1 jeśli

wyrażenie jest ujemne, 0 jeśli jest równe 0 i 1 dla wyrażeń dodatnich.

Funkcja `exp(x)` zwraca wartość wyrażenia e^x , natomiast funkcja `log(x)` zwraca logarytm z podanej liczby. Domyślnie jest to logarytm naturalny, ale można zmienić podstawę podając wartość argumentu `base`.

Funkcja `abs(x)` zwraca wartość bezwzględną (absolutną) wyrażenia.

Ćwiczenie

Oblicz wartość wyrażenia: $2 \cdot \sqrt{\pi} + \log_2 8$.

Rozwiązanie:

```
2*sqrt(pi)+log(8,2)
```

```
## [1] 6.544908
```

Zadania

Oblicz wartość wyrażeń:

1. $\frac{2^3 \cdot 6^2}{(\frac{1}{2})^2 \cdot (\frac{4}{5})^3}$
2. $\sqrt[3]{\frac{6-3.5}{2^{11}}}$
3. $\pi + \sqrt{e^4}$
4. $5! - \log_{10} 100$
5. $|1 - e|$

Chapter 2

Struktury danych

Prezentacja

2.1 Obiekty

W R praktycznie wszystko jest obiektem. Może to być zbiór danych, ale także wykres czy mapa. Zasadnicza różnica to klasa tych obiektów i operacje jakie mogą być na nich wykonywane.

Funkcje w R wymagają jako argumentów określonych typów obiektów - stąd tak ważna jak znajomość istniejących struktur.

Każdy obiekt w R możemy przypisać do tzw. obiektu nazwanego. Wówczas jest przechowywany w pamięci i można się do niego odwołać. Przypisanie odbywa się za pomocą operatora `<-`.

```
nazwa <- obiekt  
obiekt -> nazwa
```

Można także przypisywać obiekty z wykorzystaniem znaku równości `=`, ale nie jest to zalecane ponieważ symbol ten jest używany w innych miejscach np. do deklarowania wartości argumentów w funkcji.

W R dostępna jest funkcja `assign`, która także umożliwia przypisanie nazwy do obiektu:

```
assign("nazwa", obiekt)
```

2.2 Wektor

Wektor jest najprostszym typem danych w R. Najczęściej korzysta się z trzech typów wektorów:

- logicznych
- liczbowych
- tekstowych

Wektor tworzy się z wykorzystaniem funkcji `c()`.

2.2.1 Wektor wartości logicznych

Przyjmuje wartości *prawda* lub *falsz*:

```
c(TRUE, FALSE, FALSE)
```

```
## [1] TRUE FALSE FALSE
```

lub w skróconej wersji:

```
c(T, F, F)
```

```
## [1] TRUE FALSE FALSE
```

Do sprawdzenia długości wektora używa się funkcji `length`:

```
length(c(T, F, F))
```

```
## [1] 3
```

lub korzystając z obiektu nazwanego:

```
wart_log <- c(T,F,F)
length(wart_log)
```

```
## [1] 3
```

Wektory można także utworzyć poprzez replikację określonej wartości lub wektora z wykorzystaniem funkcji `rep`. Funkcja ta przyjmuje co najmniej dwa argumenty: obowiązkowo `x` - wektor wejściowy oraz jeden z następujących: `times` - liczba powtórzeń elementów wektora `x`, `each` - liczba powtórzeń elementów wektora `x` (wyjaśnienie różnicy poniżej) lub `length.out` - oczekiwana długość wektora wynikowego.

Trzy równoważne zapisy:

```
rep(x = c(T,F), times = 3)
```

```
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
```

```
rep(c(T,F), times = 3)
```

```
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
```

```
rep(c(T,F), 3)
```

```
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
```

A tak to wygląda z argumentem `each`:

```
rep(c(T,F), each = 3)
```

```
## [1] TRUE TRUE TRUE FALSE FALSE FALSE
```

Wykorzystanie argumentu `length.out`:

```
rep(c(T,F), length.out = 5)
```

```
## [1] TRUE FALSE TRUE FALSE TRUE
```

2.2.2 Wektor wartości liczbowych

W wektorze możemy przechowywać także liczby:

```
c(1, 3, -5, 2.5, .6) # nie trzeba pisać zera przed ułamkiem
```

```
## [1] 1.0 3.0 -5.0 2.5 0.6
```

Połączenie dwóch wektorów to także wektor:

```
c(c(1,2,3), c(3.5,4,4.5))
```

```
## [1] 1.0 2.0 3.0 3.5 4.0 4.5
```

Pojedyncza liczba też jest jednoelementowym wektorem:

```
length(2)
```

```
## [1] 1
```

Proste ciągi o różnicy równej 1 można generować wykorzystując dwukropek:

```
1:10
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

lub

```
c(-5:-1,1:5)
```

```
## [1] -5 -4 -3 -2 -1 1 2 3 4 5
```

Do generowania ciągów liczbowych o różnych różnicach wykorzystuje się funkcję `seq`, która przyjmuje następujące argumenty. Wartość początkową `from`, wartość końcową `to` oraz jeden z następujących: `by` - krok lub `length.out` - oczekiwana długość wektora.

To samo co 1:10

```
seq(1, 10, 1)
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

Wartości niecałkowite:

```
seq(1, 2, 0.2)
```

```
## [1] 1.0 1.2 1.4 1.6 1.8 2.0
```

Wektor wartości malejących:

```
seq(10, 1, by=1) # błędny zapis
```

```
## Error in seq.default(10, 1, by = 1): wrong sign in 'by' argument
```

```
seq(10, 1, by=-1) # poprawny zapis
```

```
## [1] 10 9 8 7 6 5 4 3 2 1
```

Tworzenie wektora w oparciu o argument `length.out` - funkcja sama dobiera krok:

```
seq(1, 7, length.out = 13)
```

```
## [1] 1.0 1.5 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5 6.0 6.5 7.0
```

Do generowania liczb pseudolosowych służy funkcja `runif(n)`, która do poprawnego wywołania wymaga tylko jednego argumentu - długości wektora wynikowego. Domyślnie losowane są liczby z przedziału $[0; 1]$ (tak jak w funkcji `los()` w Excelu), można to jednak zmienić podając odpowiednie wartości argumentów `min` i `max`.

```
runif(6)
```

```
## [1] 0.645086575 0.390191614 0.631319303 0.064505834 0.234808099 0.002340352
```

Obserwacje można także generować z innych rozkładów:

- `rnorm` - rozkład normalny,
- `rchisq` - rozkład χ^2 ,
- `rt` - rozkład t-studenta,
- itp.

Wykaz wszystkich dostępnych w R rozkładów uzyskamy wywołując polecenie `help("Distributions")`.

Za każdym uruchomieniem jednej z wymienionych wyżej funkcji losujących wartości z danego rozkładu otrzymamy inne wartości:

```
runif(5)
```

```
## [1] 0.3709323 0.6485009 0.6707011 0.8488970 0.1535202
```

```
runif(5)
```

```
## [1] 0.3556888 0.7778026 0.8799568 0.5817308 0.8520157
```

Powtarzalność wyników możemy uzyskać ustalając ziarno generatora:


```
set.seed(123)
runif(5)

## [1] 0.2875775 0.7883051 0.4089769 0.8830174 0.9404673

set.seed(123)
runif(5)

## [1] 0.2875775 0.7883051 0.4089769 0.8830174 0.9404673
```

2.2.3 Wektor wartości tekstowych

W wektorze może być przechowywany tekst - wówczas poszczególne elementy zapisujemy w cudzysłowie lub apostrofach:

```
c("ala", "ma", "kota")

## [1] "ala" "ma" "kota"

c('ala', 'ma', 'kota')

## [1] "ala" "ma" "kota"
```

W RStudio wygodniej używać cudzysłowu, ponieważ program automatycznie go zamyka.

Istnieje także stała zawierająca litery alfabetu:

```
letters

## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"

LETTERS

## [1] "A" "B" "C" "D" "E" "F" "G" "H" "I" "J" "K" "L" "M" "N" "O" "P" "Q" "R" "S"
## [20] "T" "U" "V" "W" "X" "Y" "Z"
```

2.2.4 Przeciążanie wektora

Jeśli w wektorze pomieszczymy kilka typów zmiennych to R przekształci poszczególne wartości, tak aby stracić jak najmniej informacji:

```
c(TRUE, 2, 5)

## [1] 1 2 5

c(3, "cztery", 5)

## [1] "3" "cztery" "5"
```

W pierwszym przypadku wartość `TRUE` została przekształcona na odpowiednik liczbowy - 1. Z kolei w drugim przykładzie podane liczby zostały przekonwertowane na tekst.

2.2.5 Operacje na wektorach

Na wektorach logicznych i liczbowych można wykonywać operacje arytmetyczne np. mnożenie:

```
1:10*2
```

```
## [1] 2 4 6 8 10 12 14 16 18 20
```

Wektor liczbowy plus wektor liczbowy:

```
1:10 + c(1,2)
```

```
## [1] 2 4 4 6 6 8 8 10 10 12
```

Wektor liczbowy razy wektor liczbowy:

```
1:10 * c(1,2)
```

```
## [1] 1 4 3 8 5 12 7 16 9 20
```

Wektor liczbowy razy wektor logiczny:

```
1:10 * c(T, F)
```

```
## [1] 1 0 3 0 5 0 7 0 9 0
```

Długości obu wektorów muszą być odpowiednie:

```
1:10 * c(T,F,T)
```

```
## Warning in 1:10 * c(T, F, T): longer object length is not a multiple of shorter
## object length
```

```
## [1] 1 0 3 4 0 6 7 0 9 10
```

Dłuższy z wektorów musi być wielokrotnością krótszego.

Siłą rzeczy działania arytmetyczne na wektorach tekstowych nie są możliwe:

```
c("jeden", "dwa", "trzy", "cztery") * c(T,F)
```

```
## Error in c("jeden", "dwa", "trzy", "cztery") * c(T, F): non-numeric argument to bin
c("jeden", "dwa", "trzy", "cztery") + c(1,2)
```

```
## Error in c("jeden", "dwa", "trzy", "cztery") + c(1, 2): non-numeric argument to bin
```

2.2.6 Operacje agregujące

Na wektorach można także wykonywać operacje agregujące:

Funkcja	Działanie
mean()	średnia elementów
sum()	suma elementów
prod()	iloczyn elementów
var()	wariancja elementów
sd()	odchylenie standardowe elementów
median()	mediana elementów
quantile()	kwantyl danego rzędu
min()	minimum
max()	maksimum

Obliczenie skośności i kurtozy jest możliwe po zainstalowaniu pakietu `e1071`. Wówczas mamy dostęp do funkcji:

Funkcja	Działanie
skewness()	skośność elementów
kurtosis()	kurtoza elementów

Suma wektora numerycznego:

```
sum(1:10)
```

```
## [1] 55
```

Suma i średnia wektora logicznego:

```
sum(c(T, F, F, T))
```

```
## [1] 2
```

```
mean(c(T, F, F, T))
```

```
## [1] 0.5
```

Korzystanie z funkcji pochodzących z pakietów zewnętrznych wymaga wskazania skąd pochodzi dana funkcja. Można to zrobić na dwa sposoby: funkcją `library(pakiet)` - wówczas wszystkie funkcje z tego pakietu są wczytywane do pamięci i można do nich sięgać bezpośrednio lub wskazując przed nazwą funkcji z jakiego pakietu pochodzi.

Wczytanie pakietu:

```
library(e1071)
skewness(c(1,2,3,4,5,7,9,11,13))
```

```
## [1] 0.3451259
```

lub równoważnie:

```
e1071::skewness(c(1,2,3,4,5,7,9,11,13))
```

```
## [1] 0.3451259
```

Podsumowanie rozkładu wektora można także uzyskać z wykorzystaniem funkcji `summary(x)`:

```
summary(1:10)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.00   3.25   5.50   5.50   7.75   10.00
```

Działa także na wektorach tekstowych:

```
summary(c("jeden", "dwa", "trzy", "cztery"))
```

```
##      Length      Class      Mode
##           4 character character
```

2.2.7 Sprawdzanie typu wektora

Do określenia typu wektora służy funkcja `typeof`, `class` lub `mode`.

```
typeof(wart_log)
```

```
## [1] "logical"
```

Sprawdzenie czy obiekt jest danego typu odbywa się z wykorzystaniem dedykowanych funkcji z przyrostkiem `is`.

```
is.logical(wart_log)
```

```
## [1] TRUE
```

```
is.character(wart_log)
```

```
## [1] FALSE
```

2.2.8 Rzutowanie wektorów

Czasami jako np. argument funkcji będzie wymagany inny typ wektora aniżeli aktualnie posiadany w pamięci. Można wówczas spróbować przekształcić taki wektor z wykorzystaniem funkcji rozpoczynającej się od `as.:`

```
typeof(wart_log)
```

```
## [1] "logical"
```

```
as.numeric(wart_log)
```

```
## [1] 1 0 0
```

```
typeof(as.numeric(wart_log))
```

```
## [1] "double"
```

2.2.9 Indeksowanie wektorów

Aby uzyskać dostęp do części wektora korzysta się z indeksatora w postaci nawiasów kwadratowych. Utworzymy nowy wektor zawierający liczby całkowite od 10 do 20:

```
wart_10_20 <- seq(10,20)
wart_10_20
```

```
## [1] 10 11 12 13 14 15 16 17 18 19 20
```

a następnie wybieramy trzecią obserwację:

```
wart_10_20[3]
```

```
## [1] 12
```

Możemy także odwołać się do większego zakresu:

```
wart_10_20[3:5]
```

```
## [1] 12 13 14
```

I wybranych elementów:

```
wart_10_20[c(1,3,5)]
```

```
## [1] 10 12 14
```

W ten sposób można także modyfikować odpowiednie elementy wektora:

```
wart_10_20[7] <- 90
```

Wybór obserwacji większych od 15:

```
wart_10_20[wart_10_20>15]
```

```
## [1] 90 17 18 19 20
```

Z kolei następujący zapis zwróci nam wektor wartości logicznych:

```
wart_10_20 > 15
```

```
## [1] FALSE FALSE FALSE FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE
```

2.2.10 Wartości nieliczbowe

Brak danych w R jest przedstawiany jako wartość NA (ang. *not available*) i może powodować trudności z wywoływaniem niektórych funkcji:

```
v_na <- c(1,2,1,NA,1)
v_na
```

```
## [1] 1 2 1 NA 1
```

```
sum(v_na)
```

```
## [1] NA
```

W związku z tym większość funkcji ma zaimplementowany dodatkowy argument służący do obsługi tego typu wartości, który najczęściej nie uwzględnia tych wartości w obliczeniach:

```
sum(v_na, na.rm = TRUE)
```

```
## [1] 5
```

Oprócz braku danych podczas obliczeń możemy natrafić na wartości nieokreślone `NaN` (ang. *not a number*) oraz nieskończone `Inf` (ang. *infinity*).

```
0/0
```

```
## [1] NaN
```

```
1/0
```

```
## [1] Inf
```

```
sqrt(-10)
```

```
## Warning in sqrt(-10): NaNs produced
```

```
## [1] NaN
```

W R istnieje także wartość `NULL`, która jest podstawowym typem danych a nie wartością. `NULL` można traktować jako odpowiednik zbioru pustego. Jest stosowany np. w funkcjach, które niczego nie zwracają.

```
v_null <- c(1,2,1,NULL,1)
v_null
```

```
## [1] 1 2 1 1
```

```
sum(v_null)
```

```
## [1] 5
```

2.2.11 Zadania

1. Ile wynosi suma elementów większych od 10 dla następujących liczb: 12, 5, 20, 18, 8.5, 10, 4, 101, -2?

2. Z wykorzystaniem funkcji `seq` i na podstawie wektora ... dokonaj przekształcenia tworząc następujący wektor: 2 0 0 4 0 0 6 0 0 8 0 0.
3. Dane są dwa wektory - a: 2, 3, 7, 8, 2, b: 9, 1, 2, 0, 2. Jakiego typu będzie wektor będący wynikiem działania $a \leq b$?
4. Uzupełnij wektor `letters` o polskie litery diakrytyzowane. Jaka długość ma nowo utworzony wektor?
5. Wylosuj z rozkładu normalnego 1000 obserwacji z ziarnem równym 76. Ile wynosi kurtosa tych wartości?

2.3 Macierz

Macierze są wykorzystywane w R do przechowywania np. odległości pomiędzy punktami czy wskazywania sąsiedztwa obszarów geograficznych.

Do tworzenia macierzy służy funkcja `matrix`:

```
m <- matrix(1:6, nrow = 2, ncol=3)
m
```

```
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
```

Z wykorzystaniem wybranych funkcji można sprawdzić wymiary macierzy, liczbę wierszy oraz kolumn:

```
dim(m)
```

```
## [1] 2 3
```

```
ncol(m)
```

```
## [1] 3
```

```
nrow(m)
```

```
## [1] 2
```

Macierz może także zawierać tekst:

```
matrix(letters[1:9], nrow=3)
```

```
##      [,1] [,2] [,3]
## [1,] "a"  "d"  "g"
## [2,] "b"  "e"  "h"
## [3,] "c"  "f"  "i"
```

Domyślnie macierz układana jest kolumnami. Aby to zmienić należy dodać argument `byrow=TRUE`:

```
matrix(letters[1:9], nrow=3, byrow=TRUE)
```

```
##      [,1] [,2] [,3]
## [1,] "a"  "b"  "c"
## [2,] "d"  "e"  "f"
## [3,] "g"  "h"  "i"
```

Jeśli liczba elementów wejściowych jest mniejsza iloczyn podanej liczby kolumn i wierszy to w brakujące miejsce wstawiane są elementy z początku wektora wejściowego:

```
matrix(letters[1:7], nrow=3, byrow=TRUE)
```

```
## Warning in matrix(letters[1:7], nrow = 3, byrow = TRUE): data length [7] is not
## a sub-multiple or multiple of the number of rows [3]
```

```
##      [,1] [,2] [,3]
## [1,] "a"  "b"  "c"
## [2,] "d"  "e"  "f"
## [3,] "g"  "a"  "b"
```

Z kolei macierz diagonalną posiadającą elementy niezerowe wyłącznie na przekątnej tworzy się z wykorzystaniem funkcji `diag`. Macierz jednostkowa o wymiarach 4×4 :

```
diag(4)
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    0    0    0
## [2,]    0    1    0    0
## [3,]    0    0    1    0
## [4,]    0    0    0    1
```

Macierz diagonalna o wartościach 5 na przekątnej i wymiarach 3×3

```
diag(5, nrow=3, ncol=3)
```

```
##      [,1] [,2] [,3]
## [1,]    5    0    0
## [2,]    0    5    0
## [3,]    0    0    5
```

Funkcja `diag` umożliwia także ekstrakcję przekątnej z istniejącej już macierzy:

```
diag(matrix(letters[1:9], nrow=3))
```

```
## [1] "a" "e" "i"
```

2.3.1 Łączenie macierzy

Z wykorzystaniem funkcji `rbind` i `cbind` można odpowiednio łączyć obiekty wierszami (ang. *row bind*) lub kolumnami (ang. *col bind*):


```

rbind(m, c(99, 88, 77))

##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
## [3,]   99   88   77

cbind(m, matrix(101:104, nrow=2))

##      [,1] [,2] [,3] [,4] [,5]
## [1,]    1    3    5  101  103
## [2,]    2    4    6  102  104

```

2.3.2 Indeksowanie macierzy

Dostęp do poszczególnych elementów macierzy odbywa się z wykorzystaniem nawiasów kwadratowych, ale można podać dwie wartości - obiekt[wiersz,kolumna]:

```
m[2,1] # drugi wiersz, pierwsza kolumna
```

```
## [1] 2
```

```
m[2,] # tylko drugi wiersz
```

```
## [1] 2 4 6
```

```
m[,1] # tylko pierwsza kolumna
```

```
## [1] 1 2
```

```
m[,] # wszystkie obserwacje
```

```
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6

```

```
m[] # wszystkie obserwacje
```

```
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6

```

W ten sposób można dokonać modyfikacji konkretnych elementów macierzy:

```
m[2,1] <- 77
```

```
m
```

```
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]   77    4    6

```

2.3.3 Operacje na macierzach

Na macierzach można wywołać szereg operacji:

Operator/funkcja	Działanie
<code>a %*% b</code>	mnożenie macierzy a i b
<code>t(a)</code>	transpozycja macierzy a
<code>det(a)</code>	wyznacznik macierzy a
<code>solve(a)</code>	macierz odwrotna z a
<code>solve(a, b)</code>	rozwiązanie układu $a \cdot x = b$

Rozważmy dwie macierze:

```
a <- matrix(c(2, 3, 4, 2, 1, 2, 1, 3, 2), nrow = 3)
b <- matrix(6:1, ncol=2)
a;b
```

```
##      [,1] [,2] [,3]
## [1,]    2    2    1
## [2,]    3    1    3
## [3,]    4    2    2
```

```
##      [,1] [,2]
## [1,]    6    3
## [2,]    5    2
## [3,]    4    1
```

Aby przeprowadzić mnożenie macierzy a i b, liczba kolumn macierzy a musi być równa liczbie wierszy w macierzy b. Z kolei rozmiar macierzy wyjściowej to liczba wierszy macierzy a i liczba kolumn macierzy b.

```
a %*% b
```

```
##      [,1] [,2]
## [1,]   26   11
## [2,]   35   14
## [3,]   42   18
```

Transpozycja macierzy b:

```
t(b)
```

```
##      [,1] [,2] [,3]
## [1,]    6    5    4
## [2,]    3    2    1
```

Wyznacznik macierzy a:

```
det(a)
```

```
## [1] 6
```

Macierz odwrotna do macierzy a:

```
solve(a)
```

```
##           [,1]      [,2]      [,3]
## [1,] -0.6666667 -0.3333333  0.8333333
## [2,]  1.0000000  0.0000000 -0.5000000
## [3,]  0.3333333  0.6666667 -0.6666667
```

Wyznaczenie macierzy x w równaniu $a \cdot x = b$:

```
solve(a,b)
```

```
##           [,1]      [,2]
## [1,] -2.3333333 -1.8333333
## [2,]  4.0000000  2.5000000
## [3,]  2.6666667  1.6666667
```

```
a %*% solve(a,b)
```

```
##           [,1] [,2]
## [1,]      6    3
## [2,]      5    2
## [3,]      4    1
```

```
b
```

```
##           [,1] [,2]
## [1,]      6    3
## [2,]      5    2
## [3,]      4    1
```

2.3.4 Zadanie

1. Co powstanie po przemnożeniu macierzy przez jej macierz odwrotną?
2. Estymator parametrów beta w metodzie najmniejszych kwadratów jest dany wzorem:

$$b = (X'X)^{-1}X'y$$

Zmienna x_1 przyjmuje wartości 2,4,1,6,9,3,2,9,10,7, zmienna x_2 1.5,0.2,0.1,2,3.1,1.2,0.4,2.9,2.5,1.9, a zmienna x_0 to wektor jedynek. Te trzy zmienne tworzą macierz X . Z kolei wartości zmiennej y są następujące 12,15,10,19,26,13,13,21,29,18. Wyznacz wartość b .

```
zad1 <- matrix(1:4, nrow=2)
solve(zad1)
```

```
##      [,1] [,2]
## [1,]  -2  1.5
## [2,]   1 -0.5
```

```
zad1 %*% solve(zad1)
```

```
##      [,1] [,2]
## [1,]    1    0
## [2,]    0    1
```

2.4 Czynniki

Czynnik (ang. *factor*) służy do przechowywania danych jakościowych o małej liczbie kategorii, mierzonych na skali nominalnej i porządkowej.

Rozważmy informacje o wykształceniu:

```
wyk <- rep(c("podstawowe", "średnie", "wyższe"), c(5,3,2))
wyk
```

```
## [1] "podstawowe" "podstawowe" "podstawowe" "podstawowe" "podstawowe"
## [6] "średnie"      "średnie"      "średnie"      "wyższe"        "wyższe"
```

i dokonajmy transformacji na czynnik:

```
wyk_f <- factor(wyk)
wyk_f
```

```
## [1] podstawowe podstawowe podstawowe podstawowe podstawowe średnie
## [7] średnie      średnie      wyższe      wyższe
## Levels: podstawowe średnie wyższe
```

Funkcja `summary()` wywołana na czynniku zwraca wynik innego typu aniżeli na wektorze tekstowym:

```
summary(wyk)
```

```
##      Length      Class      Mode
##          10 character character
```

```
summary(wyk_f)
```

```
## podstawowe      średnie      wyższe
##           5           3           2
```

Jeśli chcemy zaakcentować fakt, że zmienne są mierzone na skali porządkowej dodajemy argument `ordered=TRUE`:

```
wyk_of <- factor(wyk, ordered = TRUE)
wyk_of
```

```
## [1] podstawowe podstawowe podstawowe podstawowe podstawowe średnie
## [7] średnie      średnie      wyższe      wyższe
## Levels: podstawowe < średnie < wyższe
```

W łatwy sposób możemy edytować etykiety:

```
levels(wyk_of) <- c("pod.", "śr.", "wyż.")
wyk_of
```

```
## [1] pod. pod. pod. pod. pod. śr.  śr.  śr.  wyż. wyż.
## Levels: pod. < śr. < wyż.
```

Czynniki mają szczególne znaczenie w przypadku tworzenia wykresów, gdy chcemy określić porządek wyświetlania.

2.5 Lista

Listy to ciągi złożone z elementów o dowolnych typach. Mogą przydać się w szczególności przy budowaniu funkcji, które zwracają tylko jedną wartość. Wówczas dane różnego typu mogą być zawarte w takiej liście.

Tworzenie prostej listy:

```
l <- list(TRUE, c(1,2,3,4), "element tekstowy")
l
```

```
## [[1]]
## [1] TRUE
##
## [[2]]
## [1] 1 2 3 4
##
## [[3]]
## [1] "element tekstowy"
```

Już na pierwszy rzut oka widać bardziej złożoną strukturę listy. W związku z tym odwoływanie do poszczególnych elementów będzie trochę się różnić od wektorów czy macierzy.

```
l[2] # druga lista
```

```
## [[1]]
## [1] 1 2 3 4
```

```
l[[2]] # zawartość listy
```

```
## [1] 1 2 3 4
```

```
l[[2]][3] # trzeci element wektora drugiej listy
```

```
## [1] 3
```

Listę można także rozwinąć do wektora z wykorzystaniem funkcji `unlist`:

```
unlist(l)
```

```
## [1] "TRUE"          "1"              "2"              "3"
## [5] "4"              "element tekstowy"
```

Poszczególne elementy listy można nazwać:

```
ln <- list(log=TRUE, num=c(1,2,3,4), tekst="element tekstowy")
ln
```

```
## $log
## [1] TRUE
##
## $num
## [1] 1 2 3 4
##
## $tekst
## [1] "element tekstowy"
```

Wówczas można uzyskać do nich dostęp poprzez symbol `$` i podaną nazwę:

```
ln$num
```

```
## [1] 1 2 3 4
```

```
ln[[2]] # normalne indeksowanie nadal działa
```

```
## [1] 1 2 3 4
```

```
ln$num[2]
```

```
## [1] 2
```

2.6 Ramka danych

Ramka danych to tabela, która przypomina tą z Excela zawierająca dane o różnych typach. Tworzona za pomocą funkcji `data.frame`:

```
df <- data.frame(plec=c("m", "k", "k", "m", "k", "m", "m", "m"),
                  wzrost=c(173, 170, 163, 178, 169, 180, 175, NA),
                  pali=c(T, F, F, F, T, F, NA, T))
```

W RStudio po wybraniu tego obiektu w zakładce **Environment** pojawia się przyjazne okno do przeglądania oraz poglądowego filtrowania i sortowania danych ze zbioru.

Możemy zobaczyć podsumowanie całego zbioru wywołując na nim funkcję `summary()`:

```
summary(df)
```

```
##      plec      wzrost      pali
## Length:8      Min.   :163.0  Mode :logical
## Class :character 1st Qu.:169.5 FALSE:4
## Mode  :character Median :173.0  TRUE :3
##              Mean  :172.6  NA's :1
##              3rd Qu.:176.5
##              Max.   :180.0
##              NA's   :1
```

Ramki danych można indeksować w taki sam sposób jak macierze lub z wykorzystaniem operatora `$`:

```
df[,2] # druga kolumna
```

```
## [1] 173 170 163 178 169 180 175 NA
```

```
df$wzrost # kolumna wzrost
```

```
## [1] 173 170 163 178 169 180 175 NA
```

```
df[,c("plec", "pali")]
```

```
##  plec  pali
## 1    m  TRUE
## 2    k FALSE
## 3    k FALSE
## 4    m FALSE
## 5    k  TRUE
## 6    m FALSE
## 7    m   NA
## 8    m  TRUE
```

Z kolei do wyboru obserwacji można wykorzystać warunek:

```
df[df$plec=="m",]
```

```
##  plec  wzrost  pali
## 1    m     173  TRUE
## 4    m     178 FALSE
## 6    m     180 FALSE
## 7    m     175   NA
## 8    m      NA  TRUE
```

Wyodrębnienie informacji o wzroście tylko dla kobiet i wyznaczenie średniej:

```
wzrost_k <- df$wzrost[df$plec == "k"]
wzrost_k
```

```
## [1] 170 163 169
```

```
mean(wzrost_k)
```

```
## [1] 167.3333
```

Widzimy, że dla mężczyzn nie udało się ustalić wszystkich informacji i jeden z nich nie ma podanego wzrostu, a dla drugiego brakuje informacji o paleniu papierosów. Możemy usunąć braki danych w kolumnach korzystając z funkcji `complete.cases()`:

```
df[complete.cases(df$wzrost),] # tylko zmienna wzrost
```

```
##   plec wzrost  pali
## 1    m    173  TRUE
## 2    k    170 FALSE
## 3    k    163 FALSE
## 4    m    178 FALSE
## 5    k    169  TRUE
## 6    m    180 FALSE
## 7    m    175   NA
```

```
df[complete.cases(df),] # wszystkie zmienne
```

```
##   plec wzrost  pali
## 1    m    173  TRUE
## 2    k    170 FALSE
## 3    k    163 FALSE
## 4    m    178 FALSE
## 5    k    169  TRUE
## 6    m    180 FALSE
```

Zbiory danych przechowywane są także w R i pochodzą z różnych pakietów. Wywołując funkcję `data("zbiór")` ładujemy dany zbiór do pamięci. Do szybkiego podglądu zebranych danych służy funkcja `head()`, która domyślnie wyświetla 6 pierwszych obserwacji ze zbioru:

```
data("iris")
head(iris)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
```



```
## 6          5.4          3.9          1.7          0.4 setosa
```

2.6.1 Zadania

Załaduj do pamięci zbiór o nazwie ChickWeight.

1. Ile razy jedzenie otrzymał kurczak o numerze 15?
2. Ile wynosi mediana wagi kurczaka o numerze 35?
3. Ile średnio ważyły kurczaki na diecie nr 1, a ile na diecie nr 2?

Chapter 3

Przetwarzanie danych

Prezentacja - wczytywanie danych

Prezentacja - przetwarzanie

3.1 Wprowadzenie - pakiet tidyverse

Pakiet `tidyverse` to zestaw pakietów do kompleksowego przetwarzania i wizualizacji danych. Ładuje następujące pakiety:

- `ggplot2` - tworzenie wykresów,
- `dplyr` - przetwarzanie danych,
- `tidyr` - zmiana reprezentacji danych,
- `readr` - wczytywanie danych tekstowych,
- `purrr` - programowanie funkcyjne
- `tibble` - sposób przechowywania danych,
- `stringr` - przetwarzanie tekstów,
- `forcats` - przetwarzanie faktorów

Manifest tidyverse ustala następujące zasady:

- powtórne użycie istniejących struktur danych,
- tworzenie czytelnych kodów z operatorem pipe `%>%` (ang. rura, przewód, łącznik).

Wobec tego załadujmy pakiet `tidyverse`:

```
library(tidyverse)
```

```
## -- Attaching packages ----- tidyverse 1.3.1 --  
## v ggplot2 3.3.5      v purrr   0.3.4  
## v tibble  3.1.6      v dplyr  1.0.7
```

```
## v tidyr    1.1.4      v stringr 1.4.0
## v readr    2.1.1      v forcats 0.5.1

## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
```

W konsoli pojawi się informacja o wersji załadowanych pakietów oraz o konfliktach występujących pomiędzy pakietami. Konflikty te wynikają z takich samych nazw funkcji w różnych pakietach. Kolejność wczytywania pakietów ma znaczenie - kolejny pakiet przykryje funkcje z wcześniej wczytanego. Wywołanie przykrytej funkcji jest możliwe poprzez zapis `nazwa_pakietu::nazwa_funkcji`.

Korzystanie z pakietu i zasad `tidyverse` to dużo bardziej czytelny kod w porównaniu do wbudowanych funkcji. Poniżej przedstawiony jest przykład przetwarzania danych polegający na filtrowaniu, wyborze kolumn oraz utworzeniu nowej zmiennej.

```
data("ChickWeight")

# bez pakietu tidyverse

chick_15 <- ChickWeight[ChickWeight$Chick=="15",]
chick_15 <- chick_15[c("weight", "Time", "Diet"),]
chick_15$weight_kg <- chick_15$weight/1000

# z pakietem tidyverse

chick_15 <- ChickWeight %>%
  filter(Chick=="15") %>%
  select(-Chick) %>%
  mutate(weight_kg=weight/1000)
```

Rozwiązanie z wykorzystaniem wbudowanych funkcji to 133 znaki, natomiast wykorzystanie `tidyverse` to 30% oszczędność miejsca i tylko 92 znaki.

3.2 Import danych

Wczytywanie danych do R jest możliwe z wielu różnych źródeł. Funkcje, które to umożliwiają zwykle mają nazwę rozpoczynającą się od `read`.

Będziemy korzystać z następujących zbiorów danych:

- movies - plik tekstowy zawierający informacje o filmach,
- bank - plik excel zawierający dane dot. kampanii marketingowej banku, opis zmiennych,
- rossmann - plik excel zawierający dane ze sklepów Rossmann,
- lotto - plik tekstowy zawierający dane z losowań Lotto.

3.2.1 Pliki CSV

Do wczytywania plików csv można wykorzystać wbudowaną funkcję `read.csv()` lub tą pochodzącą z pakietu `readr` - `read_csv()`. W obu przypadkach wynik wczytania będzie podobny.

```
movies <- read.csv("data/movies.csv")

movies2 <- read_csv("data/movies.csv")

## Rows: 2961 Columns: 11

## -- Column specification -----
## Delimiter: ","
## chr (3): title, genre, director
## dbl (8): year, duration, gross, budget, cast_facebook_likes, votes, reviews,...
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

Jeśli nas plik ma nietypową strukturę to w funkcji `read.csv()` możemy określić dodatkowe argumenty informując o nazwach kolumn obecnych w pliku (`header =`), separatorze kolumn (`sep =`) lub separatorze miejsc dziesiętnych (`dec =`)

```
movies <- read.csv(file = "data/movies.csv", header = T, sep=",", dec=".")
```

3.2.2 Pliki excel

Do wczytywania plików z Excela niezbędny jest dodatkowy pakiet `readxl`. W funkcji `read_xlsx()` podajemy jako argument nazwę pliku. Możemy także dodać nazwę lub numer arkusza w argumencie (`sheet =`) oraz zakres komórek jako wartość argumentu `range =`.

```
library(readxl)

bank <- read_xlsx("data/bank.xlsx")

# bank <- read_xlsx("data/bank.xlsx", sheet = "dane")
# bank <- read_xlsx("data/bank.xlsx", sheet = 1)

bank_a1i30 <- read_xlsx("data/bank.xlsx", range = "A1:I30")

rossmann <- read_xlsx("data/rossmann.xlsx")
```

3.2.3 Pliki tekstowe

Z kolei do wczytywania plików tekstowych wykorzystuje się funkcję `read.table()`. Wczytywany plik nie musi być zlokalizowany na dysku

twardym - może to być link internetowy.

```
lotto <- read.table("http://www.mbnet.com.pl/dl.txt")
names(lotto) <- c("lp", "data", "numery")
```

3.3 Filtrowanie

Do przetwarzania danych służą funkcje z pakietu `dplyr`. Większość z nich jako pierwszy argument przyjmuje przetwarzany zbiór danych, ale można tego uniknąć wykorzystując symbole `%>%`.

Filtrowanie polega na wybraniu obserwacji, które spełniają określony warunek lub warunki. Ze zbioru `movies` wybierzmy wszystkie komedie:

```
komedie <- filter(movies, genre=="Comedy")
```

lub alternatywnie:

```
komedie <- movies %>%
  filter(genre=="Comedy")
```

Po zmiennej, która jest filtrowana musimy podać operator porównania czyli podwójny znak równości `==`. Jeśli chcemy filtrować po większej liczbie zmiennych to kolejne warunki dodajemy po przecinku:

```
komedie_2012 <- movies %>%
  filter(genre=="Comedy", year==2012)
```

Wówczas oba warunki muszą zostać spełnione czyli pomiędzy nimi zachodzi relacja i. Równoważny zapis jest następujący:

```
komedie_2012 <- movies %>%
  filter(genre=="Comedy" & year==2012)
```

Pomiędzy warunkami może także zachodzić relacja lub. Wybieramy filmy, które są komediami **lub** miały swoją premierę w 2012 roku.

```
komedie_l_2012 <- movies %>%
  filter(genre=="Comedy" | year==2012)
```

Możliwy jest także wybór wielu kryteriów filtrowania poprzez operator `%in%`:

```
komedie_familijne <- movies %>%
  filter(genre %in% c("Comedy", "Family"))

movies_2000_2010 <- movies %>%
  filter(year %in% 2000:2010)
```

3.4 Wybieranie kolumn

Do wyboru kolumn służy funkcja `select()`. Zmodyfikujemy wcześniej utworzony zbiór komedie:

```
komedie <- movies %>%  
  filter(genre=="Comedy") %>%  
  select(title, year, duration, budget, rating)
```

Ten sam kod możemy zapisać zagnieżdżając funkcje, ale traci on w ten sposób na czytelności:

```
komedie <- select(filter(movies, genre=="Comedy"), title, year, duration, budget, rating)
```

Możemy także wskazać, które zmienne nie mają znaleźć się w zbiorze wynikowym:

```
komedie <- movies %>%  
  filter(genre=="Comedy") %>%  
  select(-genre)
```

Natomiast jeśli zmiennych jest więcej to musimy je umieścić w wektorze, żeby nie pisać przed każdą zmienną znaku minus:

```
komedie <- movies %>%  
  filter(genre=="Comedy") %>%  
  select(-genre, -director, -gross, -budget)
```

```
komedie <- movies %>%  
  filter(genre=="Comedy") %>%  
  select(-c(genre, director, gross, budget))
```

Z wykorzystaniem znaku dwukropka możemy także wskazywać zakresy zmiennych:

```
komedie <- movies %>%  
  filter(genre=="Comedy") %>%  
  select(-genre, -c(gross:reviews))
```

3.5 Tworzenie nowych zmiennych

Do utworzenia nowej zmiennej wykorzystuje się funkcję `mutate()`. Utwórzmy w naszym zbiorze nową zmienną, która będzie zawierała czas trwania filmu w godzinach:

```
komedie <- movies %>%  
  filter(genre=="Comedy") %>%
```

```
select(-genre, -c(gross:reviews)) %>%
mutate(dur_hour = duration/60)
```

Rozsądnie będzie zaokrąglić otrzymaną wartość do jednego miejsca po przecinku - służy do tego funkcja `round()`:

```
komedie <- movies %>%
  filter(genre=="Comedy") %>%
  select(-genre, -c(gross:reviews)) %>%
  mutate(dur_hour = round(duration/60,1))
```

Z kolei funkcja `transmute()` tworzy zbiór w którym jest tylko nowo utworzona kolumna:

```
komedie_t <- movies %>%
  filter(genre=="Comedy") %>%
  select(-genre, -c(gross:reviews)) %>%
  transmute(dur_hour = round(duration/60,1))
```

3.6 Zmiana nazwy zmiennej

Do zmiany nazw zmiennych służy funkcja `rename()`. Najpierw podajemy nazwę nowej zmiennej, a po znaku równości starą nazwę:

```
bank <- bank %>%
  rename(karta=kredyt)
```

Zmiany nazwy można także dokonać z wykorzystaniem funkcji `select`:

```
bank_nowy <- bank %>%
  select(lokata=wynik)
```

W takim przypadku trzeba jednak pamiętać o wypisaniu wszystkich zmiennych, które mają się znaleźć w zbiorze wynikowym.

3.7 Podsumowanie danych

Funkcja `summarise()` służy do podsumowań danych w formie zagregowanej:

```
bank %>%
  summarise(saldo_srednia=mean(saldo),
            saldo_mediana=median(saldo))
```

```
## # A tibble: 1 x 2
##   saldo_srednia saldo_mediana
##         <dbl>         <dbl>
## 1         1362.           448
```


Podsumowanie danych ma najwięcej sensu w połączeniu z funkcją grupującą.

3.8 Grupowanie

Do grupowania obserwacji służy funkcja `group_by()`. Zobaczmy jak wyglądają statystyki salda w poszczególnych grupach wykształcenia:

```
bank %>%
  group_by(wykszt) %>%
  summarise(saldo_srednia=mean(saldo),
            saldo_mediana=median(saldo))
```

```
## # A tibble: 4 x 3
##   wykszt      saldo_srednia saldo_mediana
##   <chr>          <dbl>          <dbl>
## 1 podstawowe    1251.            403
## 2 srednie       1155.            392
## 3 wyzsze        1758.            577
## 4 <NA>          1527.            568
```

Po przecinku w funkcji `group_by()` można wskazać kolejne zmienne grupujące:

```
bank %>%
  group_by(wykszt, hipoteka) %>%
  summarise(saldo_srednia=mean(saldo),
            saldo_mediana=median(saldo))
```

```
## `summarise()` has grouped output by 'wykszt'. You can override using the `.groups` argument.
```

```
## # A tibble: 8 x 4
## # Groups:   wykszt [4]
##   wykszt      hipoteka saldo_srednia saldo_mediana
##   <chr>      <chr>          <dbl>          <dbl>
## 1 podstawowe nie          1571.            521
## 2 podstawowe tak          1008.            344.
## 3 srednie   nie          1340.            416.
## 4 srednie   tak          1034.            380
## 5 wyzsze    nie          1919.            618
## 6 wyzsze    tak          1584.            543
## 7 <NA>      nie          1780.            679
## 8 <NA>      tak          1207.            442
```

Przydatna jest także funkcja `n()`, która nie przyjmuje żadnego argumentu i zwraca liczebność zbioru bądź grupy.

```
bank %>%
  group_by(wykszt) %>%
  summarise(liczebosc=n()),
```

```
saldo_srednia=mean(saldo),
saldo_mediana=median(saldo))
```

```
## # A tibble: 4 x 4
##   wyksz      liczebnosc saldo_srednia saldo_mediana
##   <chr>      <int>      <dbl>      <dbl>
## 1 podstawowe    6851      1251.      403
## 2 srednie      23202      1155.      392
## 3 wyzsze       13301      1758.      577
## 4 <NA>         1857      1527.      568
```

Jeżeli chcemy tylko wyznaczyć liczebności grup to możemy skorzystać z funkcji `count()`:

```
bank %>%
  group_by(wykszt) %>%
  count()
```

```
## # A tibble: 4 x 2
## # Groups:   wyksz [4]
##   wyksz      n
##   <chr>  <int>
## 1 podstawowe 6851
## 2 srednie   23202
## 3 wyzsze    13301
## 4 <NA>      1857
```

Jedną z kategorii zmiennej wykształcenie jest brak danych (NA). Zamienimy tą wartość na kategorię *nieustalone* z wykorzystaniem funkcji `mutate()` oraz `if_else()`. Funkcja `if_else()` przyjmuje trzy argumenty - pierwszy (`condition`) to warunek, który jest weryfikowany, następnie podajemy wartość, która ma być wprowadzona w przypadku spełnienia warunku (`true`), a na końcu wartość dla niespełnionego warunku (`false`). Jest to odpowiednik funkcji JEŻELI z Excela.

W omawianym przykładzie warunkiem jest sprawdzenie czy wartości zmiennej `wykszt` są równe NA. Jeśli tak to na ich miejsce wprowadzany jest tekst *nieustalone*, a w przeciwnym przypadku pozostaje oryginalna wartość.

```
bank %>%
  mutate(wykszt=if_else(is.na(wykszt), "nieustalone", wyksz)) %>%
  group_by(wykszt) %>%
  count()
```

```
## # A tibble: 4 x 2
## # Groups:   wyksz [4]
##   wyksz      n
##   <chr>  <int>
```

```
## 1 nieustalone 1857
## 2 podstawowe 6851
## 3 srednie 23202
## 4 wyzsze 13301
```

3.9 Sortowanie

Sortowanie jest możliwe z wykorzystaniem funkcji `arrange()`. Jako argument podajemy zmienną według, której chcemy posortować zbiór. Domyślne zbiór sortowany jest rosnąco - od wartości najmniejszych do największych:

```
bank_sort <- bank %>%
  arrange(saldo)
```

Zmiana kierunku sortowania jest możliwa po zastosowaniu funkcji `desc()`:

```
bank_sort <- bank %>%
  arrange(desc(saldo))
```

Sortowanie możemy także zastosować do wyników podsumowania danych:

```
bank %>%
  group_by(wykszt) %>%
  summarise(liczebnosc=n(),
            saldo_srednia=mean(saldo),
            saldo_mediana=median(saldo)) %>%
  arrange(saldo_srednia)
```

```
## # A tibble: 4 x 4
##   wykszt      liczebnosc saldo_srednia saldo_mediana
##   <chr>          <int>         <dbl>         <dbl>
## 1 srednie      23202         1155.          392
## 2 podstawowe   6851         1251.          403
## 3 <NA>         1857         1527.          568
## 4 wyzsze     13301         1758.          577
```

3.10 Łączenie zbiorów

W celu zaprezentowania funkcji łączących dane przygotujemy kilka zbiorów pomocniczych:

```
praca_czas <- bank %>%
  group_by(praca) %>%
  summarise(sr_czas=mean(czas))

praca_saldo <- bank %>%
  group_by(praca) %>%
```

```
summarise(sr_saldo=mean(saldo))

zawod_saldo <- bank %>%
  rename(zawod=praca) %>%
  group_by(zawod) %>%
  summarise(sr_saldo=mean(saldo))
```

Do łączenia dwóch zbiorów danych służy funkcja `inner_join()`, która jako argumenty przyjmuje nazwy zbiorów danych oraz klucz łączenia. Jeśli w obu zbiorach występują kolumny o takich samych nazwach to zostaną potraktowane jako klucz łączenia:

```
praca_czas_saldo <- inner_join(praca_czas, praca_saldo)
```

```
## Joining, by = "praca"
```

Jeśli takie kolumny nie będą istniały to wywołanie funkcji zwróci błąd:

```
praca_czas_saldo <- inner_join(praca_czas, zawod_saldo)
```

```
## Error: `by` must be supplied when `x` and `y` have no common variables.
## i use by = character() to perform a cross-join.
```

W takich przypadku należy wskazać klucz połączenia w postaci `by = c("id1"="id2")`:

```
praca_czas_saldo <- inner_join(praca_czas, zawod_saldo, by=c("praca"="zawod"))
```

Jeśli w jednym ze zbiorów nie ma wszystkich identyfikatorów, które znajdują się w drugim zbiorze to zastosowanie funkcji `inner_join()` będzie skutkowało zbiorem, w którym znajdą się tylko te obserwacje, które udało się połączyć.

```
praca_saldo_1500 <- praca_saldo %>%
  filter(sr_saldo > 1500)

inner_join(praca_czas, praca_saldo_1500, by="praca")
```

```
## # A tibble: 6 x 3
##   praca sr_czas sr_saldo
##   <dbl>   <dbl>   <dbl>
## 1     2     289.    1522.
## 2     3     254.    1764.
## 3     5     256.    1521.
## 4     7     268.    1648.
## 5     8     287.    1984.
## 6    NA     238.    1772.
```

Jeśli chcemy pozostawić niedopasowane obserwacje to należy wykorzystać jedną z funkcji - `left_join()` lub `right_join()` w zależności od tego dla którego zbioru chcemy pozostawić wszystkie informacje.

```
left_join(praca_czas, praca_saldo_1500, by="praca")
```

```
## # A tibble: 11 x 3
##   praca sr_czas sr_saldo
##   <dbl>   <dbl>   <dbl>
## 1     1     247.     NA
## 2     2     289.    1522.
## 3     3     254.    1764.
## 4     4     246.     NA
## 5     5     256.    1521.
## 6     6     263.     NA
## 7     7     268.    1648.
## 8     8     287.    1984.
## 9     9     253.     NA
## 10    10     257.     NA
## 11    NA     238.    1772.
```

3.11 Szeroka i wąska reprezentacja danych

Do wyjaśnienia kwestii szerokiej i wąskiej reprezentacji danych posłużymy się danymi z GUS dotyczącymi przeciętnego miesięcznego spożycie wybranych artykułów żywnościowych na 1 osobę w 2016 roku - plik.

```
spozycie <- read_xlsx("data/spozycie.xlsx")
```

Taka tabela jest przykładem szerokiej reprezentacji danych. Z kolei w niektórych sytuacjach wygodnie jest korzystać z wąskiej reprezentacji danych, a niektóre pakiety wręcz wymagają takich zbiorów wejściowych.

Do transformacji danych z reprezentacji szerokiej na wąską służy funkcja `gather()` (pol. *gromadzić*). Kluczowe są w niej dwa argumenty - pierwszy (`key`) określa nazwę nowej kolumny, która będzie zawierała nazwy zmiennych, a drugi (`value`) określa nazwę nowej kolumny, która będzie zawierała wartości zmiennych. Jako kolejne argumenty podaje się nazwy kolumn, które mają być transformowane lub nazwy kolumn ze znakiem minus -, które nie mają być transformowane.

```
spozycie_waskie <- spozycie %>%
  gather(artykul, spozycie, mieso, owoce, warzywa)
```

```
# spozycie_waskie <- spozycie %>%
#   gather(artykul, spozycie, -kod, -nazwa)
```

W takiej formie łatwiej podsumować dane:

```
spozycie_waskie %>%
  group_by(artykul) %>%
```

```
summarise(sr_spozycie=mean(spozycie))
```

```
## # A tibble: 3 x 2
##   artykul sr_spozycie
##   <chr>      <dbl>
## 1 mieso      5.47
## 2 owoce      3.65
## 3 warzywa    8.85
```

W porównaniu do szerokiej reprezentacji danych:

```
spozycie %>%
  summarise(sr_spozycie_mieso=mean(mieso),
            sr_spozycie_owoce=mean(owoce),
            sr_spozycie_warzywa=mean(warzywa))
```

```
## # A tibble: 1 x 3
##   sr_spozycie_mieso sr_spozycie_owoce sr_spozycie_warzywa
##   <dbl>          <dbl>          <dbl>
## 1      5.47          3.65          8.85
```

Transformacja z wąskiej do szerokiej reprezentacji danych jest możliwa z zastosowaniem funkcji `spread()` (pol. *rozprzestrzeniać*). W przypadku tej funkcji niezbędne są dwa argumenty - pierwszy (`key`) wskazuje kolumnę zawierającą nazwy dla nowych zmiennych, a drugi argument (`value`) wskazuje kolumnę zawierającą wartości dla nowych zmiennych.

```
spozycie_szerokie <- spozycie_waskie %>%
  spread(artykul, spozycie)
```

3.12 Eksport danych

Zapis zbioru danych do zewnętrznego pliku jest możliwy z wykorzystaniem funkcji `write.table()`. Jako argumenty tej funkcji określamy: zbiór danych (`x`), docelowe miejsce na dysku i nazwę pliku (`file`), separator kolumn (`sep`), separator miejsc dziesiętnych (`dec`) oraz argument `row.names = FALSE`, dzięki któremu unikniemy dodatkowych numerów wierszy.

```
write.table(spozycie_waskie, file = "data/spozycie_w.csv", sep=";", dec=".", row.names=FALSE)
```

Taki plik jest plikiem csv, który możemy otworzyć w Excelu i zapisać go z rozszerzeniem `.xlsx`. Teoretycznie istnieje pakiet `xlsx`, który umożliwia zapisywanie zbiorów od razu do Excela, ale działa w oparciu o Javę, co bywa problematyczne.

3.13 Zadania

Na podstawie zbioru `rossmann` odpowiedź na pytania:

1. Ile było sklepów o asortymencie rozszerzonym w dniu 25-02-2014?
2. W jaki dzień tygodnia średnia liczba klientów była największa w sklepie nr 101?
3. Sklep jakiego typu charakteryzuje się największą medianą sprzedaży?
4. Czy w ciągu roku odległość do najbliższego sklepu konkurencji zmieniła się dla jakiegokolwiek sklepu Rossmann?

3.14 Case study

Rozważmy sklepy Rossmann, które w 2014 roku były otwarte powyżej 300 dni w roku. Czy średnia sprzedaż wyrażona w zł w sklepach Rossmann różni się statystycznie pomiędzy grupami zdefiniowanymi przez asortyment sklepu? Dane na temat średniego kursu miesięcznego euro pobierz ze stron NBP.

Chapter 4

Wizualizacja danych

Prezentacja

4.1 Wprowadzenie

Przewodnik po wizualizacji danych

Fundamentals of Data Visualization

Będziemy działać na zbiorze dotyczącym sprzedaży w sklepach: `rossmann.xlsx` i `rossmann.RData`.

```
library(tidyverse)


# library(readxl)
#
# rossmann <- read_xlsx("data/rossmann.xlsx")
#
# save(rossmann, file="data/rossmann.RData")

# natywny format, mniejszy rozmiar, szybsze wczytywanie
load("data/rossmann.RData")

sklep77 <- rossmann %>%
  filter(sklep_id==77, czy_otwarty=="Tak")
```

Do prostych wykresów można wykorzystać wbudowaną funkcję `plot`.

```
plot(sklep77$sprzedaz, sklep77$liczba_klientow,
     xlab = "Sprzedaż", ylab = "Liczba klientów",
     main = "Sprzedaż i liczba klientów w sklepie Rossmann nr 77")
```




Jej możliwości są jednak ograniczone i stworzenie bardziej zaawansowanych grafik będzie wymagające.

Wiodącym pakietem do wizualizacji danych w R jest ggplot2:

- dokumentacja: <https://ggplot2.tidyverse.org/>
- cheatsheet
- tworzenie wykresów poprzez dodawanie (+) kolejnych warstw

4.2 Wykres punktowy


Ten sam wykres co wcześniej, ale z wykorzystaniem pakietu ggplot2.



Wykonanie krok po kroku:

1. Utworzenie siatki - określenie co chcemy na wykresie przedstawić

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow))
```




W zależności od typu wykresu w funkcji `aes` mogą znaleźć się argumenty:

- `x`
- `y`
- `fill`
- `size`
- `color`
- `shape`


2. Określenie w jaki sposób chcemy te dane przedstawić - funkcja zawsze zaczyna się od `geom_`:

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow)) +  
  geom_point()
```




3. Edytowanie etykiet osi - funkcje `xlab` i `ylab`:

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow)) +  
  geom_point() +  
  xlab("Sprzedaż") +  
  ylab("Liczba klientów")
```




4. Dodanie tytułu - funkcja ggtitle

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow)) +  
  geom_point() +  
  xlab("Sprzedaż") +  
  ylab("Liczba klientów") +  
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77")
```



5. Zmiana motywu - funkcja rozpoczynająca się od `theme_`:

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow)) +  
  geom_point() +  
  xlab("Sprzedaż") +  
  ylab("Liczba klientów") +  
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +  
  theme_light()
```



Dostępne motywy:

- theme_bw
- theme_classic
- theme_dark
- theme_gray
- theme_light
- theme_linedraw
- theme_minimal
- theme_void

Powyższe motywy są zaimplementowane w pakiecie ggplot2, ale można także skorzystać z dodatkowych pakietów:

- theme_bbc
- theme_xkcd

Albo stworzyć swój własny motyw.


Zadanie

Zmień motyw wykresu na wybrany przez siebie.

Dodamy teraz do wykresu kolejną cechę - rozpoczęcie promocji, żeby sprawdzić czy istnieje jakaś tendencja.


```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow, color=czy_promocja)) +  
  geom_point() +  
  xlab("Sprzedaż") +
```

```
ylab("Liczba klientów") +  
ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +  
theme_light()
```



Okazuje się dosyć interesująco, niemniej nazwa etykiety legendy nie wygląda zbyt dobrze. Żeby to poprawić musimy użyć funkcji `scale_`


```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow, color=czy_promocja)) +  
  geom_point() +  
  xlab("Sprzedaż") +  
  ylab("Liczba klientów") +  
  scale_color_discrete(name = "Promocja") +  
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +  
  theme_light()
```

W funkcji `scale_` musimy podać w jaki sposób daną cechę wizualizujemy (x/y/color/...) oraz jakiego jest typu. Oprócz nazwy w tej funkcji możemy określić wiele innych kwestii takich jak:


- wyświetlane etykiety
- początek i koniec osi
- kolory wariantów
- etykiety wariantów

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow, color=czy_promocja)) +  
  geom_point() +  
  scale_x_continuous(name = "Sprzedaż") +  
  scale_y_continuous(name = "Liczba klientów") +  
  scale_color_discrete(name = "Promocja") +  
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +  
  theme_light()
```




Zmiana pozycji legendy możliwa jest z wykorzystaniem funkcji `theme`:

```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow, color=czy_promocja)) +  
  geom_point() +  
  scale_x_continuous(name = "Sprzedaż") +  
  scale_y_continuous(name = "Liczba klientów") +  
  scale_color_discrete(name = "Promocja") +  
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +  
  theme_light() +  
  theme(legend.position = "bottom")
```



```
ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow, color=czy_promocja)) +  
  geom_point() +  
  geom_smooth(method = "lm") +  
  scale_x_continuous(name = "Sprzedaż") +  
  scale_y_continuous(name = "Liczba klientów") +  
  scale_color_discrete(name = "Promocja") +  
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +  
  theme_light() +  
  theme(legend.position = "bottom")
```

```
## `geom_smooth()` using formula 'y ~ x'
```




4.3 Histogram

Rozkład cechy można ocenić na podstawie histogramu - domyślnie rysowanych jest 30 słupków.


```
ggplot(data = sklep77, aes(x=sprzedaz)) +  
  geom_histogram()
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```




W funkcji `geom_histogram` można podać liczbę słupków (`bins`) albo ich szerokość (`binwidth`). Poniżej zastosowano słupki o szerokości 1000 euro.

```
ggplot(data = sklep77, aes(x=sprzedaz)) +  
  geom_histogram(binwidth = 1000)
```



Dodatkowo w tej funkcji można określić kwestie estetyczne - kolory obramowania i wypełnienia słupków.

```
ggplot(data = sklep77, aes(x=sprzedaz)) +  
  geom_histogram(binwidth = 500, color = "black", fill = "green")
```




Pełna lista nazw kolorów znajduje się tutaj.

Z wykorzystaniem funkcji `scale_` zmieniamy nazwy osi (`name`), granice (`limits`) oraz wskazania liczbowe (`breaks`). Te dwie ostatnie wartości musimy deklarować jako wektory z wykorzystaniem funkcji `c()`.

```
ggplot(data = sklep77, aes(x=sprzedaz)) +  
  geom_histogram(binwidth = 500,  
                 color = "black", fill = "green") +  
  scale_x_continuous(name = "Sprzedaż",  
                     limits = c(4000,17000),  
                     breaks = c(5000, 8000, 11000)) +  
  scale_y_continuous(name = "Liczebność",  
                     limits = c(0,50))
```


```
## Warning: Removed 2 rows containing missing values (geom_bar).
```



Można zaautomatyzować proces dobierania wskazań liczbowych z wykorzystaniem funkcji `seq` opisanej szerzej w rozdziale 2.1.2.

```
ggplot(data = sklep77, aes(x=sprzedaz)) +
  geom_histogram(binwidth = 500,
                 color = "black", fill = "green") +
  scale_x_continuous(name = "Sprzedaż",
                    limits = c(4000,17000),
                    breaks = seq(4000, 17000, 1500)) +
  scale_y_continuous(name = "Liczebność",
                    limits = c(0,50))
```

```
## Warning: Removed 2 rows containing missing values (geom_bar).
```




4.4 Wykres pudełkowy

Wykres pudełkowy umożliwia porównywanie rozkładów cechy wg zmiennej grupującej. Wymogiem jest aby na osi x znajdowała się zmienna grupująca, a na osi y cecha analizowana.

Przeanalizujemy sprzedaż według kolejnych dni tygodnia.

```
ggplot(sklep77, aes(x=dzien_tyg, y=sprzedaz)) + geom_boxplot()
```

```
## Warning: Continuous x aesthetic -- did you forget aes(group=...)?
```





Zdecydowanie nie jest wykres jakiego oczekiwaliśmy. Wynika to z faktu, że dzień tygodnia w zbiorze danych jest zapisany jako zmienna numeryczna, natomiast prawidłowym typem dla zmiennej grupującej jest typ tekstowy lub czynnik (faktor). Ten typ danych został szczegółowo opisany w części 2.3.

Dokonujemy zatem zamiany typu danych:

```
sklep77 <- sklep77 %>%
  mutate(dzien_tyg=factor(x = dzien_tyg,
                           levels = 1:6,
                           labels = c("Pon", "Wt", "Śr", "Czw", "Pt", "Sob"),
                           ordered = TRUE))


ggplot(sklep77, aes(x=dzien_tyg, y=sprzedaz)) +
  geom_boxplot()
```



Z tego wykresu można już odczytać, że najwyższa mediana sprzedaży występuje w poniedziałek, a najniższa w środę.


Jeżeli kategorii jest dużo to można obrócić wykres z wykorzystaniem funkcji `coord_flip`.

```
ggplot(sklep77, aes(x=dzien_tyg, y=sprzedaz)) +  
  geom_boxplot() +  
  coord_flip()
```



Użycie tej funkcji powoduje wyłącznie obrócenie wykresu. Nazwy osi nie uległy zmianie pomimo, że zostały zamienione. Odwrócimy jeszcze kolejność etykiet dnia tygodnia, tak aby na górze był poniedziałek.

```
ggplot(sklep77, aes(x=dzien_tyg, y=sprzedaz)) +
  geom_boxplot() +
  coord_flip() +
  scale_x_discrete(limits = rev(levels(sklep77$dzien_tyg)))
```



4.5 Wykres słupkowy

W zależności od typu danych wejściowych, wykres słupkowy można stworzyć na dwa sposoby:

- dane jednostkowe - `geom_bar` - funkcja sama oblicza wartości do wyświetlenia,
- dane zagregowane - `geom_col` - funkcja otrzymuje już obliczone wartości.

Sprawdźmy ile jest sklepów o danym asortymencie. W tym celu potrzebujemy informację o sklepie i typie oferowanego asortymentu.


```
rossmann_asort <- rossmann %>%
  select(sklep_id, sklep_asort) %>%
  distinct()

glimpse(rossmann_asort)
```

```
## Rows: 1,115
## Columns: 2
## $ sklep_id    <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 14, 15, 16, 17, 18, ~
## $ sklep_asort <chr> "Podstawowy", "Podstawowy", "Podstawowy", "Rozszerzony", "~
```

W funkcji `aes` podajemy tylko kolumnę zawierającą dane do zliczenia.

```
ggplot(rossmann_asort, aes(x=sklep_asort)) +  
  geom_bar()
```




Natomiast użycie funkcji `geom_col` wymaga samodzielnego obliczenia wartości:

```
rossmann_asort2 <- rossmann_asort %>%  
  count(sklep_asort)  
  
glimpse(rossmann_asort2)
```

```
## Rows: 3  
## Columns: 2  
## $ sklep_asort <chr> "Extra", "Podstawowy", "Rozszerzony"  
## $ n           <int> 9, 593, 513
```

Wartość do wyświetlenia podajemy w funkcji `aes` w argumente `y`.


```
ggplot(rossmann_asort2, aes(x=sklep_asort, y=n)) +  
  geom_col()
```



Uporządkujemy etykiety osi x (obecnie są wyświetlane w kolejności alfabetycznej) tworząc czynnik.

```
rossmann_asort2 <- rossmann_asort2 %>%  
  mutate(sklep_asort=factor(x = sklep_asort,  
                             levels = c("Podstawowy",  
                                           "Rozszerzony",  
                                           "Extra"),  
                             ordered = T))  
  
glimpse(rossmann_asort2)
```

```
## Rows: 3  
## Columns: 2  
## $ sklep_asort <ord> Extra, Podstawowy, Rozszerzony  
## $ n          <int> 9, 593, 513  
  
ggplot(rossmann_asort2, aes(x=sklep_asort, y=n)) +  
  geom_col()
```



Do wykresu słupkowego możemy dodać jeszcze jedną zmienną. W tym przypadku będzie to typ sklepu.


```
rossmann_asort3 <- rossmann %>%
  select(sklep_id, sklep_asort, sklep_typ) %>%
  distinct() %>%
  count(sklep_asort, sklep_typ) %>%
  mutate(sklep_asort=factor(x = sklep_asort,
                            levels = c("Podstawowy",
                                       "Rozszerzony",
                                       "Extra"),
                            ordered = T))

glimpse(rossmann_asort3)

## Rows: 9
## Columns: 3
## $ sklep_asort <ord> Extra, Podstawowy, Podstawowy, Podstawowy, Roz~
## $ sklep_typ <chr> "b", "a", "b", "c", "d", "a", "b", "c", "d"
## $ n <int> 9, 381, 7, 77, 128, 221, 1, 71, 220
```


Uwzględnienie kolejnej zmiennej jest możliwe jako argument `fill` w funkcji `aes`.

```
ggplot(rossmann_asort3, aes(x=sklep_asort, y=n, fill=sklep_typ)) +
  geom_col()
```




Domyślnie kategorie są układane jedna na drugą - `stack`. Można je ułożyć obok siebie dodając argument `position = "dodge"` w funkcji `geom_col`.

```
ggplot(rossmann_asort3, aes(x=sklep_asort, y=n, fill=sklep_typ)) +  
  geom_col(position = "dodge")
```




Możemy jeszcze dodać etykiety słupków wykorzystując funkcję `geom_text`, w której trzeba podać argumenty definiujące położenie wartości etykiet. Wartości tych argumentów będą zależały od typu wykresu.

```
ggplot(rossmann_asort3, aes(x=sklep_asort, y=n, fill=sklep_typ)) +
  geom_col(position = "dodge") +
  geom_text(aes(label = n),
            position = position_dodge(width = 0.9),
            vjust = -0.3)
```



Zmienimy jeszcze nazwę legendy za pomocą funkcji `scale_fill_discrete`. Wykorzystujemy tę konkretną funkcję ze względu na to, że typ sklepu jest argumentem `fill` w funkcji `aes` oraz cechą jakościową (`discrete`).


```
ggplot(rossmann_asort3, aes(x=sklep_asort, y=n, fill=sklep_typ)) +
  geom_col(position = "dodge") +
  geom_text(aes(label = n),
            position = position_dodge(width = 0.9),
            vjust = -0.3) +
  scale_fill_discrete(name = "Typ sklepu")
```



4.6 Wykres kafelkowy


Do wizualizacji tabeli częstości można użyć wykresu kafelkowego. W tym celu najpierw zliczamy wystąpienia wariantów cech `czy_promocja` oraz `czy_swieto_szkolne` i wynik przekazujemy bezpośrednio do funkcji `ggplot()`.

```
sklep77 %>%
  count(czy_promocja, czy_swieto_szkolne) %>%
  ggplot(aes(x = czy_promocja,
             y = czy_swieto_szkolne,
             fill = n)) +
  geom_tile()
```




Aby dodać do tego wykresu etykiety posłużymy się funkcją `geom_label()`

```
sklep77 %>%  
  count(czy_promocja, czy_swieto_szkolne) %>%  
  ggplot(aes(x = czy_promocja,  
             y = czy_swieto_szkolne,  
             fill = n)) +  
  geom_tile() +  
  geom_label(aes(label = n), color = "white")
```



Zwykle patrząc na wykres podświadomie zakładamy, że ciemniejszy kolor oznacza wyższe wartości, natomiast jasny małe liczby. W tym przypadku układ kolorów jest odwrócony. Musimy odpowiednio dobrać kolory, aby to poprawić. Bardzo przydatne narzędzie znajduje się pod adresem: <http://colorbrewer2.org/>. Następnie korzystamy z funkcji `scale_fill_gradient`, w której określamy tylko kolor początkowy i końcowy.

```
sklep77 %>%
  count(czy_promocja, czy_swieto_szkolne) %>%
  ggplot(., aes(x = czy_promocja,
                y = czy_swieto_szkolne,
                fill = n)) +
  geom_tile() +
  geom_label(aes(label = n), color = "white") +
  scale_fill_gradient(low = "#66c2a4",
                     high = "#005824")
```

Wynika to z faktu, że dzień tygodnia jest traktowany jak zmienna numeryczna, a data jest zmienną tekstową. Konwersja tekstu na datę jest możliwa z wykorzystaniem pakietu `lubridate`. W tym pakiecie każda część daty ma swój akronim, który później jest wykorzystywany w odpowiednich funkcjach:

- y - rok (year)
- m - miesiąc (month)
- d - dzień (day)
- h - godzina (hour)
- m - minuta (minute)

Przykłady funkcji:

- `ymd` - konwertuje tekst zapisany w postaci rok-miesiąc-dzień na obiekt daty
- `dmy_hm` - konwertuje tekst zapisany w postaci dzień-miesiąc-rok godzina:minuta na obiekt daty
- `month` - pobiera z obiektu daty informację o miesiącu
- `year` - pobiera z obiektu daty informację o roku
- `week` - pobiera z obiektu daty informację o tygodniu roku


Według powyższych reguł korzystamy z funkcji `ymd()` do konwersji daty w naszym zbiorze.

```
library(lubridate)
```

```
sklep77a <- sklep77 %>%
```

```
mutate(dzien_tyg=as.factor(dzien_tyg),
       data=ymd(data))

ggplot(sklep77a, aes(x=data,
                    y=sprzedaz,
                    color=dzien_tyg)) +
  geom_point()
```



4.8 Facets

```
sr_sprzedaz <- rossmann %>%
  filter(sprzedaz > 0) %>%
  group_by(sklep_id, sklep_asort) %>%
  summarise(sprzedaz_sr=mean(sprzedaz))
```

`summarise()` has grouped output by 'sklep_id'. You can override using the `.groups` argument.


```
odleglosc <- rossmann %>%
  select(sklep_id, sklep_konkurencja) %>%
  distinct()
```

```
sprzedaz_odleglosc <- inner_join(sr_sprzedaz, odleglosc, by="sklep_id")
```

```
ggplot(sprzedaz_odleglosc, aes(x=sprzedaz_sr, y=sklep_konkurencja)) +
```

```
geom_point() +
facet_wrap(~ sklep_asort)
```

```
## Warning: Removed 3 rows containing missing values (geom_point).
```



```
sr_sprzedaz_prom <- rossmann %>%
  filter(sprzedaz > 0) %>%
  group_by(sklep_id, czy_promocja) %>%
  summarise(sprzedaz_sr=mean(sprzedaz))
```

```
## `summarise()` has grouped output by 'sklep_id'. You can override using the `.groups`
sprzedaz_prom_odl <- inner_join(sr_sprzedaz_prom, odleglosc)
```

```
## Joining, by = "sklep_id"
```


```
head(sprzedaz_prom_odl)
```

```
## # A tibble: 6 x 4
## # Groups:   sklep_id [3]
##   sklep_id czy_promocja sprzedaz_sr sklep_konkurencja
##     <dbl>   <chr>           <dbl>           <dbl>
## 1         1 Nie           4288.           1270
## 2         1 Tak           5274.           1270
## 3         2 Nie           3902.            570
## 4         2 Tak           6295.            570
## 5         3 Nie           5286.          14130
```



```
## 6          3 Tak          8790.          14130
ggplot(sprzedaz_prom_odl, aes(x=sprzedaz_sr, y=sklep_konkurencja, color=czy_promocja)) +
  geom_point()
```

```
## Warning: Removed 6 rows containing missing values (geom_point).
```



Zamiana reprezentacji danych na szeroką.

```
sprzedaz_prom_odl_wide <- sprzedaz_prom_odl %>%
  spread(czy_promocja, sprzedaz_sr)

head(sprzedaz_prom_odl_wide)
```

```
## # A tibble: 6 x 4
## # Groups:   sklep_id [6]
##   sklep_id sklep_konkurencja Nie    Tak
##   <dbl>      <dbl> <dbl> <dbl>
## 1       1          1270 4288. 5274.
## 2       2           570 3902. 6295.
## 3       3          1413 5286. 8790.
## 4       4           620 9030. 10686.
## 5       5          2910 3473. 6084.
## 6       6           310 4189. 6295.
```

I na wąską.

```
sprzedaz_prom_odl_long <- sprzedaz_prom_odl_wide %>%
  gather(czy_promocja, sprzedaz_sr, Nie, Tak)

head(sprzedaz_prom_odl_long)

## # A tibble: 6 x 4
## # Groups:   sklep_id [6]
##   sklep_id sklep_konkurencja czy_promocja sprzedaz_sr
##     <dbl>         <dbl> <chr>         <dbl>
## 1         1             1270 Nie             4288.
## 2         2              570 Nie             3902.
## 3         3            14130 Nie             5286.
## 4         4              620 Nie             9030.
## 5         5            29910 Nie             3473.
## 6         6              310 Nie             4189.
```

4.9 Wykres interaktywny

Za pomocą pakietu `plotly` w prosty sposób można zamienić statystyczny wykres `ggplot` na interaktywny.

```
library(plotly)

p <- ggplot(data = sklep77, aes(x=sprzedaz, y=liczba_klientow, color=czy_promocja)) +
  geom_point() +
  scale_x_continuous(name = "Sprzedaż") +
  scale_y_continuous(name = "Liczba klientów") +
  scale_color_discrete(name = "Promocja") +
  ggtitle("Sprzedaż i liczba klientów w sklepie Rossmann nr 77") +
  theme_light() +
  theme(legend.position = "bottom")

plotly::ggplotly(p)
```

Zadanie

Stwórz trzy grafiki dla danych dotyczących filmów.

```
filmy <- read.csv("data/movies.csv")

summary(filmy)
```

```
##      title          genre      director      year
## Length:2961      Length:2961      Length:2961      Min.   :1920
## Class :character Class :character Class :character 1st Qu.:1999
## Mode  :character Mode  :character Mode  :character Median :2004
##                                     Mean  :2003
```

```

##                                     3rd Qu.:2010
##                                     Max.    :2016
##      duration      gross      budget      cast_facebook_likes
##  Min.    : 37.0  Min.    :    703  Min.    :    218  Min.    :    0
##  1st Qu.: 95.0  1st Qu.: 12276810  1st Qu.: 11000000  1st Qu.: 2241
##  Median :106.0  Median : 34703228  Median : 26000000  Median : 4604
##  Mean   :109.6  Mean   : 58090401  Mean   : 40619384  Mean   : 12394
##  3rd Qu.:119.0  3rd Qu.: 75590286  3rd Qu.: 55000000  3rd Qu.: 16926
##  Max.   :330.0  Max.   :760505847  Max.   :300000000  Max.   :656730
##      votes      reviews      rating
##  Min.    :    5  Min.    :    2.0  Min.    :1.600
##  1st Qu.: 19918  1st Qu.: 199.0  1st Qu.:5.800
##  Median : 55749  Median : 364.0  Median :6.500
##  Mean   : 109308  Mean   : 503.3  Mean   :6.389
##  3rd Qu.: 133348  3rd Qu.: 631.0  3rd Qu.:7.100
##  Max.   :1689764  Max.   :5312.0  Max.   :9.300

```

Z racji mnogości gatunków można ograniczyć się do kilku wybranych.

Chapter 5

Programowanie w R

Prezentacja

5.1 Instrukcje warunkowe

Za pomocą instrukcji `if` możemy warunkowo wykonywać kod. Ogólna postać jest następująca:

```
if(warunek){  
  # kod wykonany jeśli warunek jest równy TRUE  
} else if(warunek) {  
  # kod wykonany jeśli warunek jest równy TRUE  
} else {  
  # kod wykonany jeśli warunek jest równy FALSE  
}
```

Element `warunek` musi zwracać wartość logiczną `TRUE` albo `FALSE`. Chcąc uwzględnić więcej niż jeden warunek należy wykorzystać odpowiedni operator łączenia:

- `i` : `&&`
- `lub` : `||`

5.2 Funkcje

Funkcję ograniczają potrzebę kopiowania kodu i ułatwiają wprowadzanie zmian.

Stworzenie funkcji wymaga:

- wymyślenia nazwy funkcji,
- określenia elementów wejściowych,
- umieszczenia kodu w ciele funkcji.

Istnieją pewne dobre praktyki tworzenia funkcji:

- nazwy funkcji powinny być czasownikami,
- podkreślnik vs. notacja camelCase i konsekwencja stosowania,
- wspólny przedrostek np. `rnorm`, `runif`.

5.3 Pętle

Pętlę są wykorzystywane w sytuacji, w której chcemy powtórzyć wykonanie kodu.